

# Heurističko rešavanje problema minimalnog broja zadovoljivih formula

Aleksa Papić      Aleksandar Stefanović

17. septembar 2022.

## Sadržaj

<b>1</b>	<b>Uvod</b>	<b>2</b>
<b>2</b>	<b>Opis algoritama</b>	<b>2</b>
2.1	Kodiranje jedinki . . . . .	2
2.2	Ocena kvaliteta jedinki . . . . .	2
2.3	Rešavanje algoritmom grube sile . . . . .	3
2.4	Rešavanje genetskim algoritmom . . . . .	3
2.4.1	Operator selekcije . . . . .	3
2.4.2	Operator ukrštanja . . . . .	4
2.4.3	Operator mutacije . . . . .	4
2.4.4	Uslov zaustavljanja . . . . .	4
2.5	Rešavanje memetskim algoritmom . . . . .	4
2.5.1	Operator optimizacije . . . . .	5
<b>3</b>	<b>Rezultati</b>	<b>7</b>
<b>4</b>	<b>Zaključak</b>	<b>7</b>

# 1 Uvod

Problem minimalne zadovoljivosti iskazne formule  $f$  (eng. MIN-SAT) je optimizaciona varijanta problema zadovoljivosti (eng. SAT) u kojoj se traži valuacija  $v$  takva da je broj klausa formule  $f$  tačnih u valuaciji  $v$  minimalan. Poznato je da je ovaj problem NP-težak [1].

U ovom radu ćemo posmatrati naredno modifikaciju ovog problema datu u [2]:

**Definicija 1.1** (Problem minimalnog broja zadovoljivih formula). Neka je dat par  $(U, C)$  gde je  $U$  skup iskaznih promenljivih, a  $C$  skup iskaznih formula u 3KNF (eng. 3CNF). Rešenje problema minimalnog broja zadovoljivih formula nad  $(U, C)$  je valuacija  $v$  za promenljive iz skupa  $U$  takva da je broj formula iz skupa  $C$  zadovoljenih tom valuacijom minimalan.

Iz definicije se može zaključiti da svaka instanca MIN-SAT problema odgovara nekoj instanci problema 1.1 u kojoj je broj klausa svake formule iz  $C$  jednak jedan.

Razmotrićemo i uporediti performanse jednog genetskog algoritma i više varijanti memetičkih algoritama za rešavanje problema 1.1.

## 2 Opis algoritama

U ovom poglavlju ćemo dati opis nekoliko pristupa u rešavanju problema 1.1.

### 2.1 Kodiranje jedinki

Pre razmatranja konkretnih algoritama, opisaćemo način kodiranja jedinki, tj. način predstavljanja konkretnih valuacija u okviru problema 1.1.

**Definicija 2.1** (Kodiranje jedinki). Neka je dat par  $(U, C)$  kao u 1.1 i neka je skup promenljivih  $U = \{p_1, \dots, p_n\}$ . Tada je valuacija  $v$  nad skupom promenljivih  $U$  niz binarnih brojeva  $(x_1, \dots, x_n) \in \{0, 1\}^n$  takav da  $x_i$  odgovara konkretizovanoj vrednosti promenljive  $p_i$ .

### 2.2 Ocena kvaliteta jedinki

Ocenu kvaliteta jedinki u okviru problema 1.1 ćemo zadati preko tzv. fitnes funkcije jedinke.

**Definicija 2.2** (Fitnes funkcija). Neka je  $v$  neka jedinka, tj. konkretna valuacija (2.1) za par  $(U, C)$  definisan kao u problemu 1.1. Fitnes funkcija

$fitness : \{0, 1\}^n \rightarrow (0, 1]$  je zadana sa  $fitness(v) = \frac{1}{sat(v)+1}$ , gde je  $sat(v)$  broj iskaznih formula iz  $C$  zadovoljenih u valuaciji  $v$ .

Iz date definicije se može zaključiti da je jedinka  $v_1$  bolja od jedinke  $v_2$  u kontekstu problema 1.1 ako i samo ako je  $fitness(v_1) > fitness(v_2)$ .

Broj zadovoljenih formula u valuaciji  $v$  se može dobiti kao  $sat(v) = \frac{1}{fitness(v)} - 1$ , ali se zbog računa u pokretnom zarezu predlaže zaokruživanje na najbliži ceo broj, tj.  $sat(v) = round(\frac{1}{fitness(v)} - 1)$ .

## 2.3 Rešavanje algoritmom grube sile

Naivni algoritam kojim se problem rešava grubom silom proverava sve moguće valuacije u problemu. Ukoliko je  $U$  skup promenljivih u problemu 1.1, takvih valuacija je  $2^{|U|}$ . Iako je egzakatan, ovaj algoritam je praktično neprimenljiv za sve osim najmanje probleme zbog svoje eksponencijalne složenosti.

## 2.4 Rešavanje genetskim algoritmom

Prvi heuristički algoritam koji ćemo razmotriti je genetski algoritam. Opisaćemo operatore koje ćemo koristiti, kao i uslov zaustavljanja. Detaljan opis algoritma i mogućih modifikacija se može videti u [3].

---

### Algoritam 1: Genetski algoritam

---

```

 $t \leftarrow 0;$ 
 $P_0 \leftarrow generisi\_populaciju();$ 
while nije ispunjen uslov zaustavljanja do
     $P_{sel} \leftarrow selekcija(P_t);$ 
     $P_{t+1} \leftarrow ukrstanje(P_{sel});$ 
     $P_{t+1} \leftarrow mutacija(P_{t+1});$ 
     $t \leftarrow t + 1;$ 
end

```

---

### 2.4.1 Operator selekcije

Za selekciju jedinki za reprodukciju koristićemo ruletsku selekciju. Verovatnoća izbora neke jedinke  $v$  jednaka je  $\frac{fitness(v)}{\sum_{u \in P_t} fitness(u)}$ , gde je  $P_t$  populacija jedinki u tekućoj iteraciji algoritma 1.

### 2.4.2 Operator ukrštanja

Za ukrštanje jedinki prilikom reprodukcije koristićemo jednopoziciono ukrštanje. Dve jedinke,  $r_1 = (x_1, \dots, x_n)$  i  $r_2 = (y_1, \dots, y_n)$ , izabrane za roditelje u fazi selekcije kreiraju dva potomka,  $p_1$  i  $p_2$ , izborom *tačke preseka*  $k$  iz diskretne uniformne raspodele nad vrednostima  $\{1, \dots, n\}$ . Tada će važiti  $p_1 = (x_1, \dots, x_k, y_{k+1}, \dots, y_n)$  i  $p_2 = (y_1, \dots, y_k, x_{k+1}, \dots, x_n)$ .

### 2.4.3 Operator mutacije

Operator mutacije koji ćemo koristiti sa nekom verovatnoćom  $p \in U(0, 1)$ , koja se zadaje kao parametar algoritma 1, invertuje jedan od bitova jedinke nad kojom se sprovodi mutacija.

### 2.4.4 Uslov zaustavljanja

Kao uslov zaustavljanja koristićemo maksimalni broj iteracija algoritma 1, kao i maksimalni broj iteracija bez promene u najboljoj jedinki. Obe vrednosti se zadaju kao parametri algoritma.

## 2.5 Rešavanje memetskim algoritmom

Još jedan tip algoritama koje ćemo razmotriti su memetski algoritmi. Ovi algoritmi predstavljaju kombinaciju više različitih heurističkih pristupa rešavanju problema [4].

Konkretna implementacija koju ćemo razmotriti kombinuje genetski algoritam opisan u prethodnom poglavlju sa nekom S-metaheuristikom, a mi ćemo ih obraditi tri. Sledi uopšteni algoritam:

---

**Algoritam 2:** Memetski algoritam

---

```
 $t \leftarrow 0;$ 
 $P_0 \leftarrow \text{generisi\_populaciju}();$ 
while nije ispunjen uslov zaustavljanja do
     $P_{sel} \leftarrow \text{selekcija}(P_t);$ 
     $P_{t+1} \leftarrow \text{ukrstanje}(P_{sel});$ 
     $P_{t+1} \leftarrow \text{mutacija}(P_{t+1});$ 
     $P_{t+1} \leftarrow \text{optimizacija}(P_{t+1});$ 
     $t \leftarrow t + 1;$ 
end
```

---

Jedina razlika u odnosu na genetski algoritam 1 je novouvedeni operator optimizacije. Svi ostali operatori su implementirani identično kao u prethodnom poglavlju.

### 2.5.1 Operator optimizacije

Uloga operatora optimizacije je da se potencijalno poboljša svaka pojedinačna jedinka iz novonastale populacije. Ovo se suštinski postiže pozivanjem neke S-metaheuristike, koja je zadata kao parametar algoritma, nad svakom jedinkom.

**Lokalna pretraga kao operator optimizacije** Najjednostavnija S-metaheuristika koju ćemo koristiti je lokalna pretraga. Kriterijum zaustavljanja je broj iteracija koji se prosleđuje kao parametar algoritmu.

---

#### Algoritam 3: Lokalna pretraga

---

**Data:** *pocetna jedinka*

**Result:** *najbolja jedinka*

*trenutna jedinka*  $\leftarrow$  *pocetna jedinka*;

**while** *nije ispunjen uslov zaustavljanja* **do**

*nova jedinka*  $\leftarrow$  *invertuj(trenutna jedinka)*;

**if** *fitness(nova jedinka) > fitness(trenutna jedinka)* **then**

*trenutna jedinka*  $\leftarrow$  *nova jedinka*;

**end**

**end**

*najbolja jedinka*  $\leftarrow$  *trenutna jedinka*;

---

**Simulirano kaljenje kao operator optimizacije** Verovatnoća kaljenja se računa po formuli  $\frac{1}{t^s}$ , gde se broj  $s$  prosleđuje kao parametar algoritma. Kriterijum zaustavljanja je broj iteracija koji se takođe prosleđuje kao parametar.

**Redukovana metoda promenljivih okolina kao operator optimizacije** Okolina veličine  $k$  neke jedinke  $v$  predstavlja skup jedinki koje se mogu dobiti invertovanjem tačno  $k$  bitova u reprezentaciji jedinke  $v$ . Maksimalna veličina okoline se prosleđuje kao parametar algoritma, kao i broj iteracija algoritma koji predstavlja kriterijum zaustavljanja.

---

**Algoritam 4:** Simulirano kaljenje

---

**Data:** *pocetna jedinka*  
**Result:** *najbolja jedinka*  
*trenutna jedinka*  $\leftarrow$  *pocetna jedinka*;  
*najbolja jedinka*  $\leftarrow$  *pocetna jedinka*;  
 $t \leftarrow 1$ ;  
**while** *nije ispunjen uslov zaustavljanja* **do**  
    *nova jedinka*  $\leftarrow$  *invertuj(trenutna jedinka)*;  
    **if** *fitness(nova jedinka) > fitness(trenutna jedinka)* **then**  
        *trenutna jedinka*  $\leftarrow$  *nova jedinka*;  
        **if** *fitness(nova jedinka) > fitness(najbolja jedinka)* **then**  
            *najbolja jedinka*  $\leftarrow$  *nova jedinka*;  
        **end**  
    **else**  
         $p \leftarrow \frac{1}{ts}$ ;  
        **if**  $q \in U(0, 1) < p$  **then**  
            *trenutna jedinka*  $\leftarrow$  *nova jedinka*;  
        **end**  
    **end**  
     $t \leftarrow t + 1$ ;  
**end**

---

---

**Algoritam 5:** Redukovana metoda promenljivih okolina

---

**Data:** *pocetna jedinka*  
**Result:** *najbolja jedinka*  
*trenutna jedinka*  $\leftarrow$  *pocetna jedinka*;  
**while** *nije ispunjen uslov zaustavljanja* **do**  
    **for**  $k \leftarrow 1$  **to** *maks. okolina* **do**  
        *nova jedinka*  $\leftarrow$  *invertuj(trenutna jedinka, k)*;  
        **if** *fitness(nova jedinka) > fitness(trenutna jedinka)* **then**  
            *trenutna jedinka*  $\leftarrow$  *nova jedinka*;  
            **break**;  
        **end**  
    **end**  
**end**  
*najbolja jedinka*  $\leftarrow$  *trenutna jedinka*;

---

**3    Rezultati**

**4    Zaključak**

## Reference

- [1] Rajeev Kohlit, Ramesh Krishnamurti, Prakash Mirchandani, *The minimum satisfiability problem*. SIAM J. Discrete Math. Vol. 7, No. 2, pp. 275-283, May 1994.
- [2] Viggo Kann, *Polynomially bounded minimization problems that are hard to approximate*. Nordic Journal of Computing 1(1994), 317–331.
- [3] Engelbrecht, Andries P. *Computational intelligence : an introduction / Andries P. Engelbrecht. – 2nd ed.*
- [4] Pablo Moscato, Carlos Cotta, Alexandre Mendes, *Memetic Algorithms*.